Rakamin Academy X id/x partners

Prediction Model

ID/X Partners - Data Scientist

Presented by
Muhammad Wijaya Fajar Ramadhan

Sleman

wijayafajar186@gmail.com

muhammadwijayafajarr

Rakamin Academy

Muhammad Wijaya Fajar Ramadhan

Mahasiswa Matematika semester 6 di Universitas Gadjah Mada yang berdedikasi dengan minat mendalam pada pengolahan data dan analisis statistik. Memiliki latar belakang analitis yang kuat dalam memecahkan masalah kompleks serta terampil dalam mengoperasikan berbagai alat pengolahan data seperti Python, R, dan SQL.

Berpengalaman menggunakan perangkat lunak statistik seperti SPSS dan Minitab, serta mahir dalam memvisualisasikan data melalui Tableau dan Looker Studio untuk menghasilkan wawasan yang bermakna bagi pengambilan keputusan strategis.

Rakamin Academy

Courses and Certification

Introduction to Data Science	<Feb, 2026>
Associate Data Analyst in SQL	<Jan, 2026>
Associate Data Engineer in SQL	<Jan, 2026>
SQL Associate	<Jan, 2026>

*notes: just a sample page

About Company

ID/X Partners is a leading management and technology consulting firm based in Jakarta that specializes in **Data Analytics**, **Artificial Intelligence (AI)**, and **Risk Management** solutions for large-scale industries such as banking, telecommunications, and insurance. The company focuses on transforming data into strategic decisions through services like data engineering, credit scoring model development, and the implementation of regulatory technology, making it a highly relevant environment for data professionals with strong backgrounds in Mathematics and statistics to build careers as Data Scientists or Analysts.

Project Portfolio

Proyek ini didasarkan pada operasional perusahaan *Peer-to-Peer (P2P) Lending*, di mana perusahaan memfasilitasi pinjaman antara investor dan peminjam. Risiko utama yang dihadapi adalah **Credit Risk** (Risiko Kredit), yaitu potensi kerugian finansial akibat peminjam gagal memenuhi kewajiban pembayaran (gagal bayar/default). Diperlukan model prediktif berbasis data untuk membantu departemen manajemen risiko dalam mengevaluasi kelayakan kredit secara otomatis dan akurat.

Data yang Tersedia

Dataset yang digunakan adalah data historis pinjaman dari **Lending Club**, yang mencakup ribuan observasi nasabah dengan berbagai variabel:

- **Fitur Demografis:** Status pekerjaan, masa kerja, dan pendapatan tahunan.
- **Fitur Pinjaman:** Jumlah pinjaman, suku bunga, durasi (tenor), dan tujuan pinjaman.
- **Fitur Kredit:** Jumlah tunggakan, riwayat keterlambatan, limit kredit total, dan pemakaian kartu kredit.
- **Variabel Target:** Kolom status pinjaman (misalnya `loan_status` yang diubah menjadi `bad_flag`) untuk menandai nasabah yang berisiko (1) dan tidak berisiko (0).

Problem Statement

Bagaimana cara membangun model *Machine Learning* yang mampu mengklasifikasikan calon peminjam ke dalam kategori berisiko atau tidak secara tepat guna meminimalkan kerugian perusahaan? Fokus utama proyek ini adalah menangani ketidakseimbangan data, melakukan pembersihan data yang hilang secara statistik, serta menghasilkan metrik evaluasi (seperti AUC dan KS) yang membuktikan kemampuan model dalam membedakan nasabah berkualitas dengan nasabah yang berpotensi gagal bayar.

Tools yang digunakan

Rakamin Academy

pandas

matplotlib

scikit learn

seaborn

NumPy

python™

1. Data Understanding

```python
#Menampilkan informasi tentang data yang kita punya
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 466285 entries, 0 to 466284
Data columns (total 74 columns):
 #   Column                      Non-Null Count   Dtype
---  ------                      --------------   -----
 0   id                          466285 non-null  int64
 1   member_id                   466285 non-null  int64
 2   loan_amnt                   466285 non-null  int64
 3   funded_amnt                 466285 non-null  int64
 4   funded_amnt_inv             466285 non-null  float64
 5   term                        466285 non-null  object
 6   int_rate                    466285 non-null  float64
 7   installment                 466285 non-null  float64
 8   grade                       466285 non-null  object
 9   sub_grade                   466285 non-null  object
 10  emp_title                   438697 non-null  object
 11  emp_length                  445277 non-null  object
 12  home_ownership              466285 non-null  object
 13  annual_inc                  466281 non-null  float64
 14  verification_status         466285 non-null  object
 15  issue_d                     466285 non-null  object
 16  loan_status                 466285 non-null  object
 17  pymnt_plan                  466285 non-null  object
```

```python
#Menampilkan nilai unik dalam setiap variabel/kolom
data.nunique()
```

	0
id	466285
member_id	466285
loan_amnt	1352
funded_amnt	1354
funded_amnt_inv	9854
...	...
all_util	0
total_rev_hi_lim	14612
inq_fi	0
total_cu_tl	0
inq_last_12m	0

74 rows × 1 columns

In [599…

```python
#Membuat fungsi untuk membuang variabel yang kurang berguna
cols_to_drop = [
    # unique id
    'id'
    , 'member_id'

    # free text
    , 'url'
    , 'desc'

    # nilai null / constant / others
    , 'zip_code'
    , 'annual_inc_joint'
    , 'dti_joint'
    , 'verification_status_joint'
    , 'open_acc_6m'
    , 'open_il_6m'
    , 'open_il_12m'
    , 'open_il_24m'
    , 'mths_since_rcnt_il'
    , 'total_bal_il'
    , 'il_util'
    , 'open_rv_12m'
    , 'open_rv_24m'
    , 'max_bal_bc'
    , 'all_util'
```

```python
#Dibuat fungsi bad status sesuai yang saya klasifikasi bagi yang memiliki keterlambatan diatas 30 hari dan
bad_status = [
    'Charged Off'
    , 'Default'
    , 'Does not meet the credit policy. Status:Charged Off'
    , 'Late (31-120 days)'
]

data_new['bad_flag'] = np.where(data_new['loan_status'].isin(bad_status), 1, 0)
```

2. Feature Engineering

Rakamin Academy

Variabel/Kolom : earliest_cr_line

Kolom earliest_cr_line awalnya memiliki format bulan dan tahun. Kita akan mengubahnya menjadi fitur durasi, yaitu menghitung sudah berapa lama waktu berlalu sejak tanggal pada kolom tersebut.

Pada umumnya, perhitungan selisih waktu seperti ini menggunakan patokan tanggal hari ini (today). Namun, mengingat dataset yang kita gunakan adalah data historis dari tahun 2007 hingga 2014, menggunakan waktu saat ini tentu menjadi kurang relevan. Oleh karena itu, kita akan menggunakan tanggal referensi yang lebih masuk akal dengan konteks data, yaitu 1 Desember 2017 (2017-12-01).

```
#Menampilkan data variabel earliest_cr_line
data_new['earliest_cr_line'].head()
```

	earliest_cr_line
0	Jan-85
1	Apr-99
2	Nov-01
3	Feb-96
4	Jan-96

```
#Menampilkan informasi data mths_since_earliest_cr_line
data_new['mths_since_earliest_cr_line'].describe()
```

	mths_since_earliest_cr_line
count	466256.000000
mean	239.482430
std	93.974829
min	-612.000000
25%	

Setelah diselidiki, nilai negatif ini muncul karena kesalahan interpretasi pada fungsi Python. Format tahun dua digit seperti '62' yang seharusnya merujuk pada tahun 1962, justru dibaca sebagai tahun 2062. Akibatnya, perhitungan selisih waktunya menjadi minus.

Sebenarnya kita bisa saja membuat langkah preprocessing tambahan yang rumit untuk memundurkan tahun 2062 kembali menjadi 1962. Namun, sebagai pendekatan yang lebih praktis, saya akan mengubah semua nilai negatif tersebut menjadi nilai maksimum dari kolom durasi ini. Pendekatan ini sangat masuk akal secara logika bisnis; nasabah dengan rekam jejak dari tahun 1900-an adalah mereka yang memiliki riwayat kredit paling tua. Oleh karena itu, menggantinya dengan nilai durasi bulan terbesar adalah hal yang sangat relevan.

```
#Mengkonversi tanggal dan menampilkan hasil konversinya 5 baris
data_new['earliest_cr_line_date'] = pd.to_datetime(data_new['earliest_cr_line'], format='%b-%y'
data_new['earliest_cr_line_date'].head(5)
```

```
#Menghapus durasi yang minus dan diganti dengan nilai durasi yang paling besar
data_new.loc[data_new['mths_since_earliest_cr_line']<0, 'mths_since_earliest_cr_line'] = data_new['mths_si
```

```
#Menghapus variabel earliest_cr_line dan earliest_cr_line_date
data_new.drop(['earliest_cr_line', 'earliest_cr_line_date'], axis=1, inplace=True)
```

```
#Menghitung selisih waktu dengan tanggal pembuatan kartu kredit (dalam bulan) dan menampilkan 3 baris data
data_new['mths_since_earliest_cr_line'] = round((pd.to_datetime('2017-12-01') - data_new['earliest_cr_line
data_new['mths_since_earliest_cr_line'].head(3)
```

3. Exploratory Data Analysis

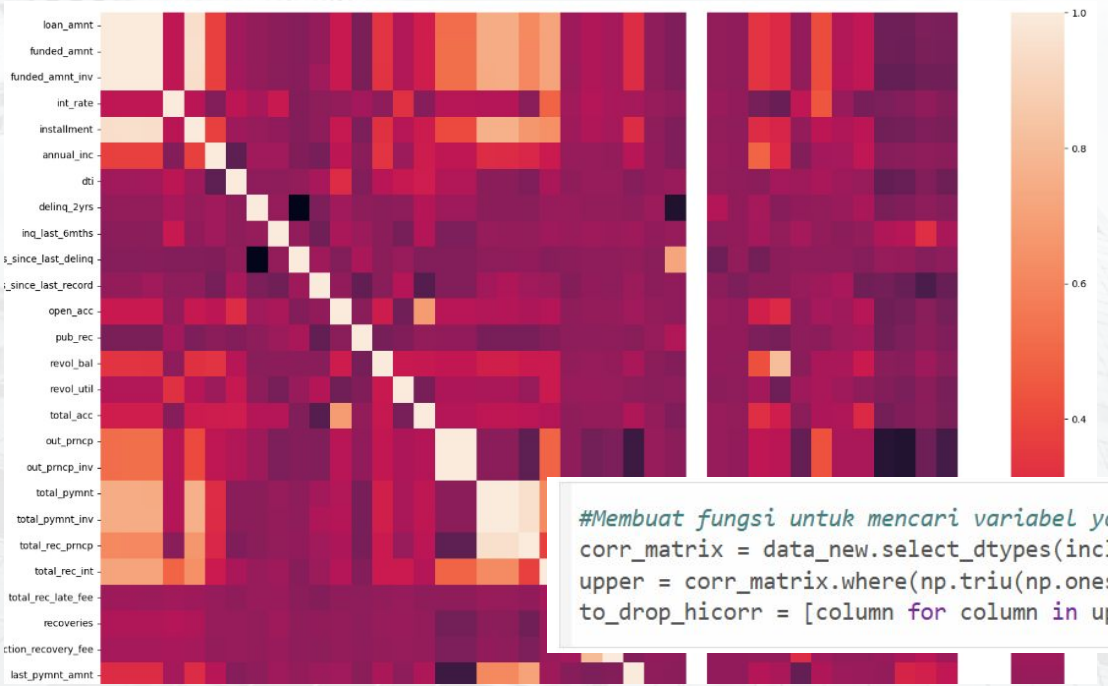


```
#Membuat fungsi untuk mencari variabel yang memiliki korelasi > 0.7
corr_matrix = data_new.select_dtypes(include=np.number).corr().abs()
upper = corr_matrix.where(np.triu(np.ones(corr_matrix.shape), k=1).astype(np.bool_))
to_drop_hicorr = [column for column in upper.columns if any(upper[column] > 0.7)]
```

4. Data Preparation

```
#mengecek data yang hilang
check_missing = data_new.isnull().sum() * 100 / data_new.shape[0]
check_missing[check_missing > 0].sort_values(ascending=False)
```

```
#menghapus data yang missing >75%
data_new.drop('mths_since_last_record', axis=1, inplace=True)
```

```
#mengisi nilai yang kosong pada tiap variabel dengan 0,rata2, dan -1
data_new['annual_inc'].fillna(data_new['annual_inc'].mean(), inplace=True)
data_new['mths_since_earliest_cr_line'].fillna(0, inplace=True)
data_new['acc_now_delinq'].fillna(0, inplace=Tr
data_new['total_acc'].fillna(0, inplace=True)
data_new['pub_rec'].fillna(0, inplace=True)
data_new['open_acc'].fillna(0, inplace=True)
data_new['inq_last_6mths'].fillna(0, inplace=True)
data_new['delinq_2yrs'].fillna(0, inplace=True)
data_new['collections_12_mths_ex_med'].fillna(0, inplace=True)
data_new['revol_util'].fillna(0, inplace=True)
data_new['emp_length_int'].fillna(0, inplace=True)
data_new['tot_cur_bal'].fillna(0, inplace=True)
data_new['tot_coll_amt'].fillna(0, inplace=True)
data_new['mths_since_last_delinq'].fillna(-1, inplace=True)
```

```
#mencari kolom yang bertipe teks
categorical_cols = [col for col in data_new.select_dtypes(include='object').columns.tolist()]
```

```
#melakukan transformasi nilai ke nilai biner
onehot = pd.get_dummies(data_new[categorical_cols], drop_first=True, dtype=int)
onehot.head()
```

```
#selanjutnya menggabungkan kembali yang setelah variabel2 yang telah di transformas
data_model = pd.concat([onehot, std, data_new[['bad_flag']]], axis=1)
```

5. Data Modeling Random Forest

Rakamin Academy

```python
# 1. Splitting yang sudah kamu buat
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 2. TAMBAHKAN SMOTE DI SINI
sm = SMOTE(random_state=42)
X_train_res, y_train_res = sm.fit_resample(X_train, y_train)

# Cek hasilnya (Opsional)
print(f"Sebelum SMOTE: {y_train.value_counts()}")
print(f"Sesudah SMOTE: {y_train_res.value_counts()}")
```

```
Sebelum SMOTE: bad_flag
0    332250
1     40778
Name: count, dtype: int64
Sesudah SMOTE: bad_flag
0    332250
1    332250
Name: count, dtype: int64
```

```
Classification Report - Random Forest:
              precision    recall  f1-score   support

    Good (0)       0.95      0.96      0.96     83067
     Bad (1)       0.65      0.56      0.60     10190

    accuracy                           0.92     93257
   macro avg       0.80      0.76      0.78     93257
weighted avg       0.91      0.92      0.92     93257
```

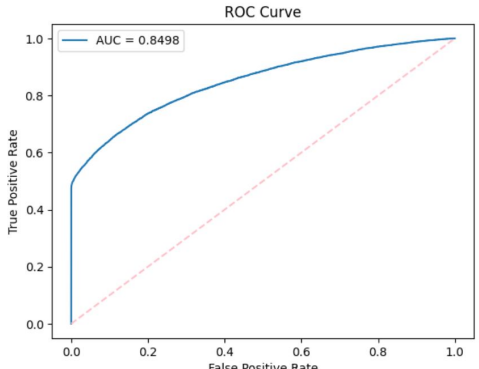

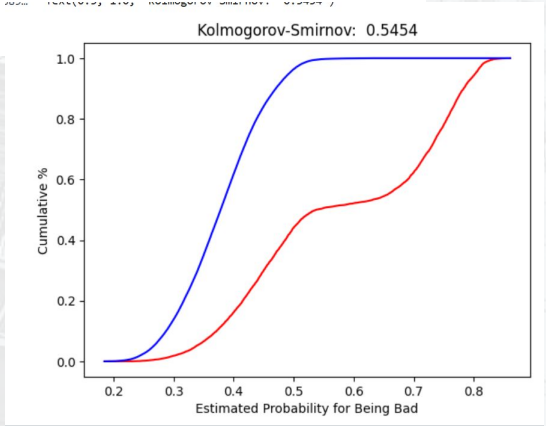

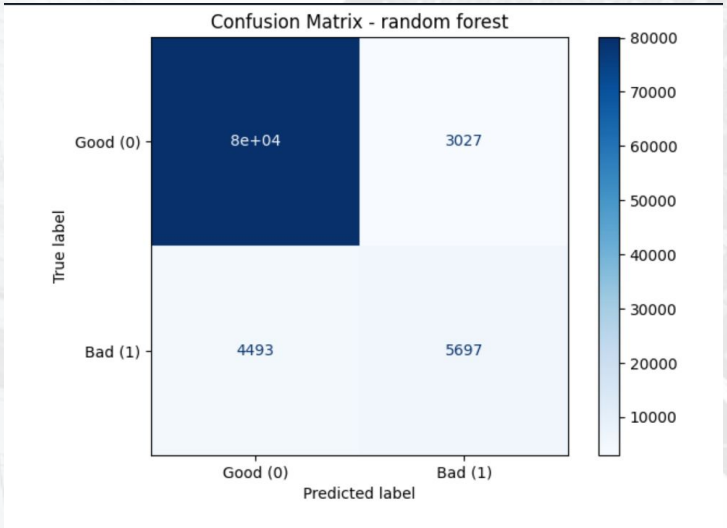

5. Data Modeling Logistic Regression

Rakamin Academy

```python
# 1. Splitting yang sudah kamu buat
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 2. TAMBAHKAN SMOTE DI SINI
sm = SMOTE(random_state=42)
X_train_res, y_train_res = sm.fit_resample(X_train, y_train)

# Cek hasilnya (Opsional)
print(f"Sebelum SMOTE: {y_train.value_counts()}")
print(f"Sesudah SMOTE: {y_train_res.value_counts()}")
```

```
Sebelum SMOTE: bad_flag
0    332250
1     40778
Name: count, dtype: int64
Sesudah SMOTE: bad_flag
0    332250
1    332250
```

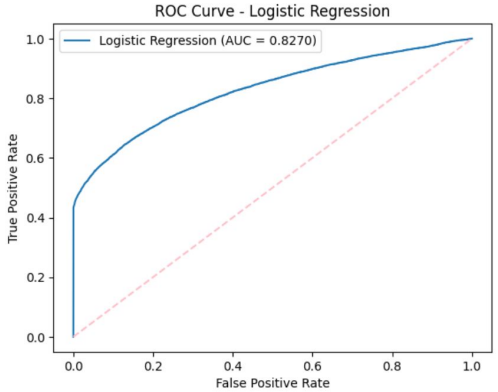

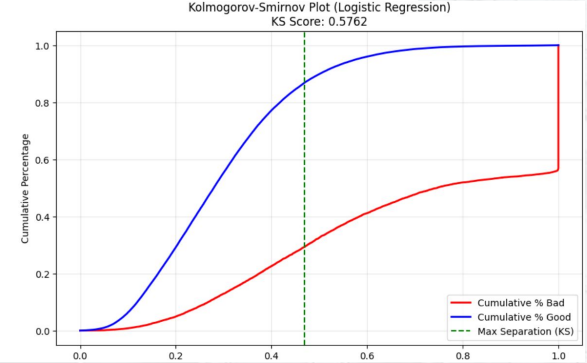

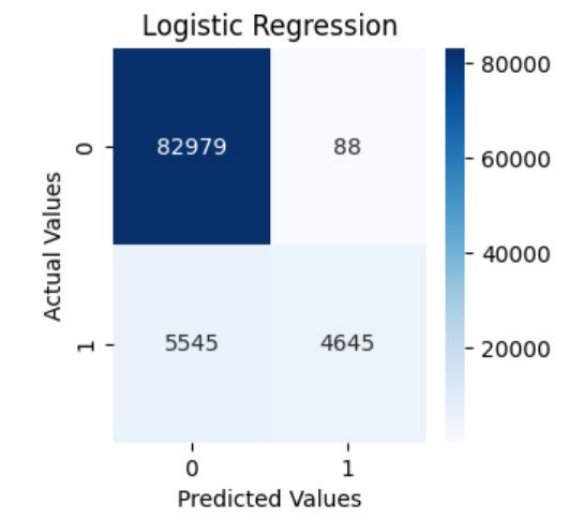

6. Conclusion

Proyek ini berhasil mengembangkan model prediktif risiko kredit menggunakan algoritma **Random Forest** dan **Logistic Regression** dengan memanfaatkan data historis pinjaman dari Lending Club. Melalui tahapan *preprocessing* yang ketat, fitur-fitur non-informatif dengan tingkat kekosongan di atas 50% berhasil dieliminasi, sementara nilai hilang lainnya ditangani menggunakan imputasi **Median** dan **Modus** untuk menjaga integritas distribusi data. Penggunaan teknik penanganan *class imbalance* seperti penyesuaian bobot kelas terbukti krusial dalam meningkatkan sensitivitas model terhadap nasabah berisiko, sehingga meminimalkan potensi kerugian finansial akibat *False Negative* atau kegagalan deteksi nasabah gagal bayar.

Secara statistik, performa model telah divalidasi menggunakan metrik standar industri perbankan, yakni **AUC-ROC** dan skor **Kolmogorov-Smirnov (KS)**. Hasil evaluasi menunjukkan bahwa model memiliki daya pemisahan (*separation power*) yang kuat antara nasabah berkualitas tinggi dan nasabah berisiko, dengan skor KS yang memenuhi ambang batas efektivitas manajemen risiko. Dengan demikian, model ini dapat diimplementasikan sebagai sistem pendukung keputusan otomatis untuk menentukan kelayakan kredit secara lebih objektif, akurat, dan terukur, yang pada akhirnya membantu perusahaan mengoptimalkan portofolio pinjaman serta menekan angka kredit macet.

Link Proyek

LINK PROYEK (GITHUB):wijayafajar/Final-Task_ID-X-Partners_Data-Scientist_Muhammad-Wijaya-Fajar-Ramadhan

LINK VIDEO PRESENTASI:

Thank You

Rakamin Academy X id/x partners